

PERRINE QUENNEHEN

Ingénieure Machine Learning | Data Scientist NLP

Pantin, 93500 | 06.65.61.98.38 | perrine.quennehen@gmail.com | [in perrine-quennehen](https://www.linkedin.com/in/perrine-quennehen) | [portfolio](#)

PROFIL

Passionnée par les technologies d'IA, machine learning et NLP (LLMs, Deep Learning, Agents), suite à mon stage de fin d'études chez Bouygues Constructions au sein du LabTP, je suis à la recherche d'un poste en CDI en tant qu'ingénieure machine learning ou data scientist NLP, afin de contribuer à des projets innovants dans votre entreprise. Rigoureuse et proactive, mes expériences précédentes mon permises de mettre à profit mes compétences mais de mener également à bien des projets concrets de NLP/ML.

EXPERIENCES

Stagiaire Ingénieure Machine Learning - Data Scientist NLP

Bouygues Construction | Guyancourt (78)

MAI 2025 – NOV 2025

- **Fine-tuning de XLM-RoBERTa** pour la **recherche sémantique** dans le domaine du BTP :
 - Pipeline de **continued pretraining** (MLM, contrastive learning) sur corpus interne (~1 M de paragraphes) avec **Transformers, Databricks, MLflow** et **Optuna**.
 - **Prétraitement** avancé (filtrage, masquage de mots-clés, gel de couches, nouveaux tokens), création d'un dataset représentatif selon les domaines BTP
 - **Évaluation multi-tâches** (recherche sémantique, clustering, distance cosinus).
 - **Amélioration de la précision** de recherche sémantique sur les documents d'appels d'offre BTP.
 - **Optimisation des hyperparamètres** avec Optuna réduisant le temps d'entraînement.
 - **Déploiement** du modèle via **OpenSearch**.

Technologies : Python, PyTorch, Transformers, Databricks, MLflow, Optuna, Docker, PySpark, Plotly, OpenSearch

Compétences : Fine-tuning, LLMs, Embeddings, MLOps, IA Générative, Optimisation, Travail d'équipe

- **Analyse NLP d'enquêtes clients :**
 - Traitement et analyse de réponses ouvertes d'enquêtes de satisfaction dans le secteur de la construction.
 - Structuration par thèmes, extraction de mots-clés (**TF-IDF**), détection d'outliers par **ACP**
 - Visualisation interactive avec intégration de verbatims augmentant l'efficacité d'analyse.

Technologies : Python (Pandas, spaCy, numpy (PCA), scikit learn (TF-IDF)), visualisation de données (Plotly)

Compétences : Autonomie, Capacité d'adaptation, Rigueur

Stagiaire Ingénieure NLP

Laboratoire MoDyCo (CNRS) | Nanterre (92)

MAI 2023 – AOÛT 2024

- **Augmentation du corpus** Naija Syncor par deux, avec l'utilisation d'alignement automatique des silences et tokens transcrits pour améliorer la couverture des données linguistiques.
- **Automatisation de l'annotation** de fichiers TextGrid afin d'optimiser l'alignement audio-transcription, réduisant le temps de traitement manuel.
- **Conception d'un lexique prosodique** pour le Naija, incluant la catégorisation linguistique via des **arbres de décisions**, structurant les données pour des analyses avancées.

Technologies : Python, SPPAS, Whisper, Praat, Natural Language Processing

Compétences : Autonomie, Méthodologie, Proactivité

FORMATIONS

Master NLP - Ingénierie Multilingue

INALCO, Sorbonne Nouvelle, Paris Nanterre | Paris, Nanterre

SEP 2023 – DEC 2025

LLCER Chinois - spécialité Natural Language Processing (NLP)

INALCO | Paris - Mention Bien

SEP 2020 – JUIN 2023

COMPETENCES TECHNIQUES

- **IA Générative & NLP :** Transformers (Hugging Face), BERT, XLM-RoBERTa, embeddings, fine-tuning, continued pretraining, semantic search, génération de texte, spaCy, NLTK
- **Machine Learning & Deep Learning :** PyTorch, TensorFlow, Scikit-learn, contrastive learning, optimisation (Optuna)
- **MLOps & Production :** MLflow, Docker, Databricks, PySpark, OpenSearch
- **Développement & Automatisation :** Python, Git, Bash
- **Analyse & Visualisation :** Pandas, Numpy, TF-IDF, PCA, Plotly, HTML reports
- **Langues :** Français (natif), Anglais (B1), Chinois (B2)